Міністерство освіти і науки України

Національному університеті "Львівська

Політехніка

Кафедра систем штучного інтелекту



Лабораторна робота №3

з дисципліни

«Інтелектуальний аналіз та візуалізація даних»

Виконала:

студентка групи ШІ-31

Потапова Світлана

Прийняла:

Торська Р. В.

Львів – 2026

Лабораторна робота № 3

Діагностика шкал вимірювання

Курс СК26 «Інтелектуальний аналіз та візуалізація даних»

Тривалість: 2 год аудиторно + 3 год самостійно · **Оцінка:** 4 бали **Файли:** `Ковід_дані_навчальні.xlsx` , `ЛР3_помилковий_аналіз.ipynb`

Шкала вимірювання визначає, які операції над змінною взагалі мають сенс. Комп'ютер цього не знає: він порахує середнє від номера телефону й не поскаржиться. Знати має вимірювач.

У цій роботі ви складаєте **паспорт восьми змінних** свого варіанта, показуєте на власних даних, які статистики для них недопустимі, і виправляєте чужий аналіз, де таких помилок десять.

```
==========================================================================
ВАРІАНТ 16   ·   Потапова Світлана   ·   ШІ-31
==========================================================================

Ваші вісім стовпців:
   1. ПІП
   2. Примітка
   3. Перебіг
   4. Виписка
   5. КТ
   6. Т вище 37,5
   7. Цукор2
   8. Д-дим2

Ваша пара для аналізу зв’язку: Ліжко днів та Вік

Ваше додаткове питання:
   Скільки стовпців файлу є ідентифікаторами? Як їх розпізнати автоматично, не дивлячись на назви?
```

```
ФАЙЛ = 'Ковід_дані_навчальні.xlsx'
df = pd.read_excel(ФАЙЛ, sheet_name='Лист1', engine='openpyxl')
МОЇ = В['стовпці']

print('Розмір набору:', df.shape)
df[МОЇ].head(8)
```

```
Розмір набору: (121, 77)
```

	ПІП	Примітка	Перебіг	Виписка	КТ	Т вище 37,5	Цукор2	Д-дим2
0	Федорюк Петро Юрійович	NaN	важкий	2022-03-10 00:00:00	20-30%	3	6.2	NaN
1	Загул Григорій Сергійович	отримував актемра, часті носові кровотечі, втрата нюху	важкий	2022-03-16 00:00:00	30-35%	3	19.3	744
2	Бондара Лариса Павлівна	часта втрата свідомості в стаціонарі	важкий	2022-01-18 00:00:00	70-80%	3	7.7	NaN
3	Ватаманюка Уляна Дмитрівна	панкреонекроз	важкий	2022-01-13 00:00:00	0.8	6	15.5	NaN
4	Бабійа Лариса Олегівна	NaN	важкий	2022-03-11 00:00:00	NaN	5 до гос	6.9	NaN
5	Ковалика ганна Андріївна	NaN	важкий	2021-12-26 00:00:00	30-40%	NaN	22.6	NaN
6	Височан Віктор Володимирович	глюкозурія, кетонові тіла в сечі, ЦД, фібриляція передс	важкий	2022-05-11 00:00:00	60-65%	NaN	12.7	NaN
7	Дзюбаа Ірина Іванівна	NaN	серед важ	2022-05-28 00:00:00	до 17%	NaN	3.7	1370

Етап 1. Паспорт змінних

Для кожного з восьми стовпців визначте шкалу вимірювання. Спирайтеся не на тип даних у pandas, а на **зміст величини**: що означають її значення і які порівняння між ними мають сенс.

Нагадування:

Шкала	Ознака
Номінальна	значення можна лише порівняти на рівність
Порядкова	є природний порядок, але відстані між сусідніми рівнями невідомі
Інтервальна	різниці мають сенс, нуль умовний
Відношень	є природний нуль, відношення мають сенс
Абсолютна	природні і нуль, і одиниця вимірювання

Окремо позначайте **ідентифікатори** — значення, що не є величиною взагалі (номер історії хвороби, прізвище, телефон).

```
# Спершу подивіться, що каже pandas — і не довіряйте йому
df[МОЇ].info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 121 entries, 0 to 120
Data columns (total 8 columns):
 #   Column       Non-Null Count  Dtype  
---  ------       --------------  -----  
 0   ПІП          121 non-null    object 
 1   Примітка     45 non-null     object 
 2   Перебіг      121 non-null    object 
 3   Виписка      120 non-null    object 
 4   КТ           44 non-null     object 
 5   Т вище 37,5  78 non-null     object 
 6   Цукор2       104 non-null    float64
 7   Д-дим2       30 non-null     object 
dtypes: float64(1), object(7)
memory usage: 7.7+ KB
```

```
# Далі — що є всередині насправді
for c in МОЇ:
    з = df[c].dropna()
    типи = ', '.join(f'{t.__name__}×{n}' for t, n in з.map(type).value_counts().items())
    print(f'--- {c}')
    print(f'    непорожніх {len(з)} з {len(df)} | унікальних {з.nunique()} | типи: {типи}')
    print(f'    приклади: {[repr(v) for v in з.unique()[:4]]}')
    print()
```

```
--- ПІП
    непорожніх 121 з 121 | унікальних 121 | типи: str×121
    приклади: ["'Федорюк Петро Юрійович'", "'Загул Григорій Сергійович'", "'Бондара Лариса Павлівна'", "'Ватаманюка

--- Примітка
    непорожніх 45 з 121 | унікальних 44 | типи: str×45
    приклади: ["'отримував актемра, часті носові кровотечі, втрата нюху'", "'часта втрата свідомості в стаціонарі'",

--- Перебіг
    непорожніх 121 з 121 | унікальних 3 | типи: str×121
    приклади: ["'важкий'", "'серед важ'", "'вкрай важкий '"]

--- Виписка
    непорожніх 120 з 121 | унікальних 90 | типи: datetime×118, str×2
    приклади: ['datetime.datetime(2022, 3, 10, 0, 0)', 'datetime.datetime(2022, 3, 16, 0, 0)', 'datetime.datetime(2

--- КТ
    непорожніх 44 з 121 | унікальних 26 | типи: float×27, str×17
    приклади: ["'20-30%'", "'30-35%'", "'70-80%'", '0.8']

--- Т вище 37,5
    непорожніх 78 з 121 | унікальних 35 | типи: str×48, int×30
    приклади: ['3', '6', "'5 до гос'", "'3 дні в стац'"]

--- Цукор2
    непорожніх 104 з 121 | унікальних 61 | типи: float×104
    приклади: ['np.float64(6.2)', 'np.float64(19.3)', 'np.float64(7.7)', 'np.float64(15.5)']

--- Д-дим2
    непорожніх 30 з 121 | унікальних 30 | типи: int×21, float×8, str×1
    приклади: ['744', '1370', '276', '0.9']
```

Заповніть паспорт

Для кожного стовпця вкажіть шкалу та **обґрунтування** — одне речення про те, чому саме ця шкала. Обґрунтування оцінюється, назва шкали сама по собі — ні.

```
ПАСПОРТ = {
    # 'назва стовпця': ('шкала', 'обґрунтування однією фразою'),
    'ПІП': ('ідентифікатор', 'позначення конкретної особи, всі значення є унікальними'),
    'Примітка': ('номінальна', 'симптоми та супутні стани пацієнтів, які можна групувати(попередньо нормалізувавши) або порівнювати на рівність'),
    'Перебіг': ('порядкова', 'порядок за зростанням важкості стану, але відстані між ними невідомі'),
    'Виписка': ('інтервальна', 'дати з часом, мають вимірювальну різницю та чіткий порядок, але точка відліку є умовною(немає нуля)'),
    'КТ': ('відношень', 'вимірює відсоток ураження легень, є природний нуль, можна порівнювати'),
    'Т вище 37,5': ('відношень', 'стовпець містить змішані числа та текст, але за суттю це вимірювання тривалості гарячки (у днях) з природним нулем, тому обрано шкалу відношень'),
    'Цукор2': ('відношень', 'біохімічний числовий показник рівня глюкози, має природний нуль, можна порівнювати через ділення'),
    'Д-дим2': ('відношень', 'фізична концентрація маркера тромбоутворення в крові, має природний нуль, можна порівнювати через ділення')
}

for c in МОЇ:
    ПАСПОРТ.setdefault(c, ('', ''))

паспорт_df = pd.DataFrame(
    [(c, ПАСПОРТ[c][0], ПАСПОРТ[c][1]) for c in МОЇ],
    columns=['Стовпець', 'Шкала', 'Обґрунтування'])
паспорт_df
```

index	Стовпець	Шкала	Обґрунтування
0	ПІП	ідентифікатор	позначення конкретної особи, всі значення є унікальними
1	Примітка	номінальна	симптоми та супутні стани пацієнтів, які можна групувати(попередньо нормалізувавши) або порівнювати на рівність
2	Перебіг	порядкова	порядок за зростанням важкості стану, але відстані між ними невідомі
3	Виписка	інтервальна	дати з часом, мають вимірювальну різницю та чіткий порядок, але точка відліку є умовною(немає нуля)
4	КТ	відношень	вимірює відсоток ураження легень, є природний нуль, можна порівнювати
5	Т вище 37,5	відношень	стовпець містить змішані числа та текст, але за суттю це вимірювання тривалості гарячки (у днях) з природним нулем, тому обрано шкалу відношень
6	Цукор2	відношень	біохімічний числовий показник рівня глюкози, має природний нуль, можна порівнювати через ділення
7	Д-дим2	відношень	фізична концентрація маркера тромбоутворення в крові, має природний нуль, можна порівнювати через ділення

```
# --- САМОПЕРЕВІРКА 1 ---
ДОПУСТИМІ = {'номінальна', 'порядкова', 'інтервальна', 'відношень',
             'абсолютна', 'ідентифікатор'}
for c in МОЇ:
    ш, об = ПАСПОРТ[c]
    assert ш.strip().lower() in ДОПУСТИМІ, f'{c}: шкалу «{ш}» не розпізнано'
    assert len(об.strip()) >= 25, f'{c}: обґрунтування закоротке'
print('Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та обґрунтування.')
```

```
Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та обґрунтування.
```

Етап 2. Допустимі статистики

Для кожного стовпця обчисліть **тільки те, що дозволяє його шкала**.

- номінальна та ідентифікатор — мода, частоти
- порядкова — додатково медіана та квантилі
- інтервальна — додатково середнє та стандартне відхилення
- відношень і абсолютна — усе, зокрема коефіцієнт варіації

Якщо для стовпця не можна порахувати нічого, крім частот, — так і напишіть.

```python
def допустима_статистика(стовпець, шкала):
    """Повертає словник статистик, дозволених для цієї шкали."""
    з = df[стовпець].dropna()
    р = {'непорожніх': len(з), 'унікальних': з.nunique()}
    ш = шкала.strip().lower()

    def clean_val(v):
        if pd.isna(v):
            return None
        if hasattr(v, 'strftime'):
            return str(v)[:10]
        if isinstance(v, (np.floating, float)):
            return round(float(v), 2)
        if isinstance(v, (np.integer, int)):
            return int(v)
        return v

    m = з.mode()
    р['мода'] = clean_val(m.iloc[0]) if not m.empty else None

    counts = з.value_counts()
    counts_dict = {clean_val(k): int(v) for k, v in counts.items()}
    р['частоти'] = counts_dict if len(counts_dict) <= 5 else dict(list(counts_dict.items())[:5])

    if ш == 'номінальна' or ш == 'ідентифікатор':
        return р

    if стовпець == 'Перебіг':
        порядок = ['серед важ', 'важкий', 'вкрай важкий ']
        cat = pd.Categorical(з, categories=порядок, ordered=True)
        codes = cat.codes[cat.codes != -1]

        if len(codes) > 0:
            p25 = int(np.percentile(codes, 25))
            p50 = int(np.percentile(codes, 50))
            p75 = int(np.percentile(codes, 75))



            р['квантиль_25'] = порядок[p25]
            р['медіана'] = порядок[p50]
            р['квантиль_75'] = порядок[p75]
    else:
        числові = pd.to_numeric(з, errors='coerce').dropna()
        if len(числові) > 0:
            р['квантиль_25'] = clean_val(числові.quantile(0.25))
            р['медіана'] = clean_val(числові.median())
            р['квантиль_75'] = clean_val(числові.quantile(0.75))

    if ш == 'порядкова':
        return р

    if 'числові' in locals() and len(числові) > 0:
        р['середнє'] = clean_val(числові.mean())
        р['std'] = clean_val(числові.std())

    if ш == 'інтервальна':
        return р

    if 'числові' in locals() and len(числові) > 0 and р['середнє'] != 0:
        р['коеф_варіації'] = round(float(р['std'] / р['середнє']), 3)

    return р


for с in МОЇ:
    print(f'--- {с}  ({ПАСПОРТ[с][0]})')
    print('   ', допустима_статистика(с, ПАСПОРТ[с][0]))
    print()
```

```
ПІП  (ідентифікатор)
{'непорожніх': 121, 'унікальних': 121, 'мода': 'Єрмолюк Григорій Павлович', 'частоти': {'Федорюк Петро Юрійович': 1, 'Загул Григорій Сергійович': 1, 'Бондара Лариса Павлівна': 1, 'Ватаманюка Уляна Дмитрівна': 1, 'Б

Примітка  (номінальна)
{'непорожніх': 45, 'унікальних': 44, 'мода': 'Поліалергетик', 'частоти': {'Поліалергетик': 2, 'отримував актемра, часті носові кровотечі, втрата нюху': 1, 'панкреонекроз': 1, 'часта втрата свідомості в стаціонарі':

Перебіг  (порядкова)
{'непорожніх': 121, 'унікальних': 3, 'мода': 'важкий', 'частоти': {'важкий': 90, 'серед важ': 30, 'вкрай важкий ': 1}, 'квантиль_25': 'важкий', 'медіана': 'важкий', 'квантиль_75': 'важкий'}

Виписка  (інтервальна)
{'непорожніх': 120, 'унікальних': 90, 'мода': '2021-09-07', 'частоти': {'2021-11-19': 3, '2021-09-07': 3, '2021-09-11': 3, '2021-09-15': 3, '2022-06-06': 3}}

КТ  (відношень)
{'непорожніх': 44, 'унікальних': 26, 'мода': 0.3, 'частоти': {0.3: 6, 0.25: 5, 0.7: 3, 0.8: 3, 0.5: 2}, 'квантиль_25': 0.25, 'медіана': 0.3, 'квантиль_75': 0.55, 'середнє': 0.4, 'std': 0.23, 'коеф_варіації': 0.575}

Т вище 37,5  (відношень)
{'непорожніх': 78, 'унікальних': 35, 'мода': 3, 'частоти': {3: 13, '3 дні в стац': 9, 2: 6, '3дні вдома': 5, 6: 4}, 'квантиль_25': 3.0, 'медіана': 3.0, 'квантиль_75': 4.0, 'середнє': 3.47, 'std': 1.48, 'коеф_варіац

Цукор2  (відношень)
{'непорожніх': 104, 'унікальних': 61, 'мода': 4.7, 'частоти': {4.7: 6, 3.7: 4, 5.6: 4, 6.9: 3, 3.9: 3}, 'квантиль_25': 4.7, 'медіана': 6.1, 'квантиль_75': 9.0, 'середнє': 7.56, 'std': 3.88, 'коеф_варіації': 0.513}

Д-дим2  (відношень)
{'непорожніх': 30, 'унікальних': 30, 'мода': 744, 'частоти': {744: 1, 1370: 1, 276: 1, 0.9: 1, '987; 554': 1}, 'квантиль_25': 531.0, 'медіана': 1063.0, 'квантиль_75': 2546.0, 'середнє': 1786.2, 'std': 1729.93, 'коеф
```

Етап 3. Три безглузді числа

`df.describe()` порахує статистики для всього, що схоже на число. Частина цих чисел не має жодного змісту.

Знайдіть **щонайменше три** такі числа у своєму наборі: обчисліть їх, а потім поясніть, чому кожне з них безглузде.

```
df_describe = df[МОЇ].copy()

df_describe['Виписка'] = pd.to_datetime(df_describe['Виписка'], errors='coerce')

for c in ['КТ', 'Т вище 37,5', 'Цукор2', 'Д-дим2']:
    df_describe[c] = pd.to_numeric(df_describe[c], errors='coerce')

stats = df_describe.describe(include='all').T
stats
```

	count	unique	top	freq	mean	min	25%	50%	75%	max	std
ПІП	121	121	Федорюк Петро Юрійович	1	NaN	NaN	NaN	NaN	NaN	NaN	NaN
Примітка	45	44	Поліалергетик	2	NaN	NaN	NaN	NaN	NaN	NaN	NaN
Перебіг	121	3	важкий	90	NaN	NaN	NaN	NaN	NaN	NaN	NaN
Виписка	118	NaN	NaN	NaN	2022-01-29 18:06:06.101694976	2021-04-27 00:00:00	2021-11-16 18:00:00	2022-03-15 00:00:00	2022-04-27 18:00:00	2022-06-22 00:00:00	NaN
КТ	27.0	NaN	NaN	NaN	0.395556	0.05	0.25	0.3	0.55	0.8	0.228866
Т вище 37,5	30.0	NaN	NaN	NaN	3.466667	1.0	3.0	3.0	4.0	7.0	1.47936
Цукор2	104.0	NaN	NaN	NaN	7.557308	3.5	4.7	6.1	9.0	22.6	3.882111
Д-дим2	29.0	NaN	NaN	NaN	1786.196897	0.25	531.0	1063.0	2546.0	5829.55	1729.928534

```
БЕЗГЛУЗДІ = [
    # ('стовпець', 'яка статистика', значення, 'чому це число нічого не означає'),
    ('Виписка', 'mean', '2022-01-29 18:06:06.101694976', 'Середня дата в інтервальній шкалі не має фізичного змісту і не характеризує пацієнтів, не відображає реальних закономірностей чи пік
    ('Д-дим2', 'min', 0.25, 'Мінімальне значення позбавлене сенсу, оскільки в стовпчику змішані різні одиниці вимірювання'),
    ('Т вище 37,5', 'mean', 3.466667, 'Обчислено лише по 30 числових рядках з 78 непорожніх, бо інші 48 були проігноровані через змішування чисел та тексту, тому середнє викривлене')
]

assert len(БЕЗГЛУЗДІ) >= 3, 'Потрібно щонайменше три приклади'
pd.DataFrame(БЕЗГЛУЗДІ, columns=['Стовпець', 'Статистика', 'Значення', 'Чому безглузде'])
```

1 to 3

index	Стовпець	Статистика	Значення	Чому безглузде
0	Виписка	mean	2022-01-29 18:06:06.101694976	Середня дата в інтервальній шкалі не має фізичного змісту і не характеризує пацієнтів, не відображає реальних закономірностей чи пікових періодів виписки
1	Д-дим2	min	0.25	Мінімальне значення позбавлене сенсу, оскільки в стовпчику змішані різні одиниці вимірювання
2	Т вище 37,5	mean	3.466667	Обчислено лише по 30 числових рядках з 78 непорожніх, бо інші 48 були проігноровані через змішування чисел та тексту, тому середнє викривлене

Етап 4. Міра зв'язку для вашої пари

Для двох змінних вашого варіанта треба оцінити зв'язок. Міру обирає **пара шкал**, а не зручність:

Поєднання шкал	Міра
відношень × відношень	кореляція Пірсона
порядкова × порядкова	рангова кореляція Спірмена
номінальна × номінальна	χ^2 та коефіцієнт Крамера (V)
відношень × бінарна номінальна	точковий бісеріальний коефіцієнт
номінальна × порядкова	коефіцієнт Крамера (V)

Обґрунтуйте вибір, обчисліть міру й поясніть результат. Окремо покажіть, **що станеться**, якщо застосувати Пірсона там, де він недопустимий, — і чому отримане число не можна інтерпретувати.

```
A, B = B['пара']
print('Ваша пара:', A, '×', B)
print()
print(f'{A}: шкала —', ПАСПОРТ.get(A, ('не у вашому списку',))[0] or '(визначте самостійно)')
print(f'{B}: шкала —', ПАСПОРТ.get(B, ('не у вашому списку',))[0] or '(визначте самостійно)')
print()
print(df[[A, B]].head(6).to_string())
```

```
Ваша пара: Ліжко днів × Вік

Ліжко днів: шкала — не у вашому списку
Вік: шкала — не у вашому списку

    Ліжко днів  Вік
0           14   55
1           22   43
2           20   54
3           20   68
4           27   65
5  9(5 у реан)   66
```

```
ОБРАНА_МІРА = 'кореляція Пірсона'
ЧОМУ_САМЕ_ВОНА = '''Обидві змінні (Ліжко-дні та Вік) належать до шкал відношень,
тому для оцінки лінійного зв\'язку між ними використовується коефіцієнт кореляції Пірсона'''     # одне-два речення

assert ОБРАНА_МІРА and len(ЧОМУ_САМЕ_ВОНА) >= 40, 'Заповніть обидва поля'

# ваш код: обчисліть обрану міру

pair_data = df[['Вік', 'Ліжко днів']].copy()

pair_data['Вік'] = pd.to_numeric(pair_data['Вік'], errors='coerce')
pair_data['Ліжко днів'] = pd.to_numeric(
    pair_data['Ліжко днів'].astype(str).str.extract(r'(\d+\.?\d*)')[0],
    errors='coerce'
)

pair_clean = pair_data.dropna()
r = pair_clean['Вік'].corr(pair_clean['Ліжко днів'], method='pearson')

print(f"Коефіцієнт кореляції Пірсона для пари 'Вік' x 'Ліжко днів': {r:.3f}")
```

```
Коефіцієнт кореляції Пірсона для пари 'Вік' x 'Ліжко днів': -0.100
```

```python
# Тепер — контрприклад: застосуйте кореляцію Пірсона незалежно від шкал
# і поясніть, чому отримане число не можна використовувати.

df_counter = df[['Перебіг', 'Ліжко днів']].dropna().copy()

df_counter['Перебіг_числовий'] = df_counter['Перебіг'].map({'серед важ': 1, 'важкий': 2, 'вкрай важкий': 3})
df_counter['Ліжко днів'] = pd.to_numeric(df_counter['Ліжко днів'].astype(str).str.extract(r'(\d+\.?\d*)')[0], errors='coerce')

r_bad = df_counter['Перебіг_числовий'].corr(df_counter['Ліжко днів'], method='pearson')

print(f"Коефіцієнт кореляції Пірсона для пари 'Перебіг' x 'Ліжко днів': {r_bad:.3f}")
```

```
Коефіцієнт кореляції Пірсона для пари 'Перебіг' x 'Ліжко днів': 0.200
```

Отримане число не можна інтерпретувати, бо змінна "Перебіг" виміряна за порядковою шкалою. Числові коди (1, 2, 3) є умовними позначеннями категорій, які штучно нав'язують рівні інтервали між станами пацієнта. Для такої шкали немає сенсу рахувати середнє значення та стандартне відхилення, які використовуються у формулі коефіцієнті Пірсона. Для цієї пари потрібно використовувати рангову кореляцію Спірмена

Етап 5. Підготовка змінних до моделі

Шкала визначає не лише статистику, а й спосіб кодування.

Шкала	Як готують до моделі
Номінальна	one-hot кодування; порядок категорій не вводять
Порядкова	впорядкована категорія або цілі коди із **заданим** порядком
Інтервальна	стандартизація; для дат — перехід до тривалостей
Відношень	нормалізація або стандартизація; можливе логарифмування
Ідентифікатор	у модель не беруть узагалі

Для кожного свого стовпця вкажіть спосіб підготовки — і **виконайте його** щонайменше для трьох стовпців різних шкал.

```python
ПІДГОТОВКА = {
    # 'стовпець': 'спосіб і коротке обґрунтування',
    'ПІП': 'не беремо у модель, оскільки це ідентифікатор особи',
    'Примітка': 'парсимо текст у декілька номінальних колонок(One-Hot кодування)',
    'Перебіг': 'кодування цілими числами із збереженням порядку',
    'Виписка': 'перехід до тривалості (розрахунок кількості днів від дати госпіталізації) та стандартизація',
    'КТ': 'стандартизація або нормалізація після вилучення текстових символів',
    'Т вище 37,5': 'нормалізація або стандартизація після вилучення текстових приміток(які можна перенести в окрему номінальну колонку)',
    'Цукор2': 'стандартизація чи нормалізація, логарифмування не потрібне бо розкид даних не великий',
    'Д-дим2': 'стандартизація, логарифмування (оскільки великий розкид значень), попередньо звівши до єдиної одиниць вимірювання'
}
for c in МОЇ:
    ПІДГОТОВКА.setdefault(c, '')

pd.DataFrame([(c, ПАСПОРТ[c][0], ПІДГОТОВКА[c]) for c in МОЇ],
             columns=['Стовпець', 'Шкала', 'Як готуємо'])
```

index	Стовпець	Шкала	Як готуємо
0	ПІП	ідентифікатор	не беремо у модель, оскільки це ідентифікатор особи
1	Примітка	номінальна	парсимо текст у декілька номінальних колонок(One-Hot кодування)
2	Перебіг	порядкова	кодування цілими числами із збереженням порядку
3	Виписка	інтервальна	перехід до тривалості (розрахунок кількості днів від дати госпіталізації) та стандартизація
4	КТ	відношень	стандартизація або нормалізація після вилучення текстових символів
5	Т вище 37,5	відношень	нормалізація або стандартизація після вилучення текстових приміток(які можна перенести в окрему номінальну колонку)
6	Цукор2	відношень	стандартизація чи нормалізація, логарифмування не потрібне бо розкид даних не великий
7	Д-дим2	відношень	стандартизація, логарифмування (оскільки великий розкид значень), попередньо звівши до єдиної одиниць вимірювання

```
# ваш код: реалізуйте підготовку для трьох стовпців різних шкал

df_prepared = df.copy()

mapping_перебіг = {'серед важ': 1, 'важкий': 2, 'вкрай важкий': 3}
df_prepared['Перебіг_clean'] = df_prepared['Перебіг'].astype(str).str.strip()
df_prepared['Перебіг_encoded'] = df_prepared['Перебіг_clean'].map(mapping_перебіг)

date_discharge = pd.to_datetime(df_prepared['Виписка'], errors='coerce')
date_admission = pd.to_datetime(df_prepared['Поступлення'], errors='coerce')
df_prepared['Тривалість_госпіталізації'] = (date_discharge - date_admission).dt.days

sugars = pd.to_numeric(df_prepared['Цукор2'], errors='coerce')
df_prepared['Цукор2_scaled'] = (sugars - sugars.mean()) / sugars.std()

df_prepared[['Перебіг_encoded', 'Тривалість_госпіталізації', 'Цукор2_scaled']].head()
```

	Перебіг_encoded	Тривалість_госпіталізації	Цукор2_scaled
0	2	14.0	-0.349631
1	2	22.0	3.024821
2	2	19.0	0.036756
3	2	20.0	2.045972
4	2	27.0	-0.169317

Перед нормалізацією обов'язково перевірте варіативність. Стовпець, у якому всі значення однакові, дасть нуль у знаменнику — і мовчазний NaN замість помилки.

```
for c in МОЇ:
    з = pd.to_numeric(df[c], errors='coerce').dropna()
    if len(з) and з.nunique() == 1:
        print(f'УВАГА: {c} — сталий стовпець, нормалізація дасть ділення на нуль')
    elif len(з) and з.max() == з.min():
        print(f'УВАГА: {c} — max дорівнює min')
print('Перевірку варіативності виконано.')
```

```
Перевірку варіативності виконано.
```

```
# --- САМОПЕРЕВІРКА 2 ---
assert all(len(ПІДГОТОВКА[c].strip()) >= 15 for c in МОЇ), \
    'Для кожного стовпця вкажіть спосіб підготовки'
assert len(БЕЗГЛУЗДІ) >= 3, 'Етап 3 не завершено'
print('Самоперевірка 2 пройдена.')
```

```
Самоперевірка 2 пройдена.
```

Етап 6. Виправлення чужого аналізу

Відкрийте файл **`ЛР3_помилковий_аналіз.ipynb`** . Це звіт, який виконується без жодної помилки й містить десять хибних місць.

Для кожного з десяти заповніть рядок нижче:

- **розділ** — номер розділу звіту;
- **що не так** — яка шкала порушена або яке припущення хибне;

- **чому число неправильне** — що саме воно означає насправді;
- **як правильно** — коректний варіант або обґрунтована відмова від показника.

Розділ	Що не так	Чому число неправильне	Як правильно
1	Некоректна інтерпретація середнього арифметичного для бінарної номінальної шкали	Число 1.50 виникло через усереднення умовних кодів 1 і 2. Воно показує лише рівну частку груп (50%/50%), а не "середній" стан пацієнтів	Для зручності краще перекодувати дані у 0 (помер) та 1 (вижив), тоді середнє значення (0.50) чітко вказуватиме на частку виживаності (50%)
2	Дублювання категорій номінальної шкали через різні скорочення	Число 4 є хибним, оскільки воно виникло через відмінності у текстових скороченнях (ж/жін та ч/чол), які насправді позначають одну й ту саму стать	Необхідно уніфікувати позначення статей, використовуючи лише один з типів скорочення
3	Застосування алфавітного сортування для порядкової шкали та відсутність уніфікації категорій	Твердження про «найлегший ступінь - важкий, найважчий - середній» виникло через сортування за абеткою замість смислового порядку шкал, а число 5.9 (середній ступінь) є безглуздим через дублювання 12 неуніфікованих синонімів та обчислення середнього для умовних індексів.	Спочатку уніфікувати всі варіанти написання ступеней, після чого явно задати логічний порядок категорій від легкого до критичного та обчислювати медіану чи моду
4	Втрата частини даних при перетворенні тексту в числа	Показники середнього ураження 39.6%, медіани 30% та стандартного відхилення 22.9% обчислені на урізаній вибірці, оскільки функція перетворення викинула в порожні значення всі рядки з діапазонами (наприклад, «30-40%»)	Спочатку очистити текст і витягнути числа (наприклад, взяти середнє для діапазонів), а вже потім рахувати показники для всього стовпчика
5	Змішування різних форматів вимірювання (дроби та відсотки) в одному стовпчику	Показники мінімуму (0.9) та середнього (82.05) є викривленими, оскільки значення 90% з набору даних було єдиним записаним у відсотковому форматі та зчиталося як дріб 0.9, що штучно тягне середню сатурацію донизу	Попередньо привести всі значення до єдиної шкали (помножити дробові значення на 100 або поділити цілі на 100), а вже потім обчислювати статистики
6	Обчислення коефіцієнта варіації для інтервальної шкали (дати) відносно умовного початку епохи та використання середньої дати як аналітичної метрики	Коефіцієнт варіації не можна рахувати для дат, оскільки вони не мають абсолютної нульової точки. Середня дата позбавлена аналітичного сенсу	Оцінювати однорідність потоку через коефіцієнт варіації кількості госпіталізацій за кожен день, а замість середньої дати аналізувати моду (пікові дні), межі дослідження (min/max) або розподіл за днями тижня
7	Використання коефіцієнта кореляції Пірсона для двох бінарних номінальних змінних	Значення 0.177 є безглуздим, оскільки коефіцієнт Пірсон оцінює лише лінійний зв'язок між кількісними неперервними величинами, а не зв'язок між категоріальними ознаками	Застосовувати спеціалізовані методи для категоріальних даних: критерій Хі-квадрат, або коефіцієнт Крамера
8	Нормалізація числових стовпчиків без попередньої перевірки їхньої варіативності	Усі значення для ФЕРИТ2 перетворилися на NaN, оскільки стовпець містив лише одне значення, що призвело до ділення на нуль (X_max - X_min = 0)	Перед нормалізацією необхідно перевіряти стовпчики на варіативність (що кількість унікальних значень більше 1) та вилучати константні стовпці
9	Необдумане видалення всіх рядків із пропусками	Стало 0 рядків, оскільки майже в кожному пацієнта є хоча б один пропущений запис в одному із стопців. Без даних подальший аналіз неможливий..	Замість повного видалення рядків слід вилучати лише ті стовпці, де занадто багато пропусків, або заповнювати відсутні значення
10	Включення у набір предикторів змінної, яка виникає тільки після настання цільової події (витік даних)	Кореляція 1 є хибним артефактом, оскільки дата розтину існує виключно у померлих пацієнтів. Ця змінна не прогнозує смерть, а фіксує її факт	Повністю вилучити дату розтину та інші посмертні показники з набору даних до початку побудови прогностичних моделей

Виправте щонайменше три помилки в коді

Оберіть три з десяти та покажіть правильне обчислення поруч із неправильним.

```
# ваш код: три правильні обчислення замість хибних
```

```
# ваш код: три правильні обчислення замість хибних

print("Помилка 2: Нестандартизовані категорії статі\n")

стать_orig = df['Стать'].value_counts()
print("Неправильно (4 статі через різний формат запису):")
print(f"Кількість унікальних статей: {df['Стать'].nunique()}")
print(стать_orig.to_string())

стать_clean = df['Стать'].astype(str).str.strip().replace({'жін': 'ж', 'чол': 'ч'})
print("\nПравильно (після уніфікації синонімів):")
print(f"Кількість унікальних статей: {стать_clean.nunique()}")
print(стать_clean.value_counts().to_string())

print("-" * 60)

print("Помилка 5: Змішування відсотків та часток у SpO2\n")

s_orig = df['spO2 без дот']
print("Неправильно (з урахуванням дробу 0.9 як мінімуму):")
print(f"  середнє  : {round(s_orig.mean(), 2)}")
print(f"  мінімум  : {round(s_orig.min(), 2)}")

s_numeric = pd.to_numeric(df['spO2 без дот'], errors='coerce')
s_clean = s_numeric.apply(lambda x: x * 100 if x <= 1 else x)

print("\nПравильно (усі значення зведені до відсотків):")
print(f"  середнє  : {round(s_clean.mean(), 2)}")
print(f"  медіана  : {round(s_clean.median(), 2)}")
print(f"  мінімум  : {round(s_clean.min(), 2)}")
print(f"  максимум : {round(s_clean.max(), 2)}")

print("-" * 60)

print("Помилка 10: Витік даних через 'Дату розтину'\n")
```

```python
дані_orig = df.select_dtypes('number').copy()
дані_orig['Дата розтину'] = pd.to_datetime(df['Дата розтину'], errors='coerce').astype('int64')
ціль = (df['помер/жив'] == 1).astype(int)

рейтинг_orig = {}
for c in дані_orig.columns:
    if c == 'помер/жив':
        continue
    r = дані_orig[c].corr(ціль)
    if pd.notna(r):
        рейтинг_orig[c] = abs(r)

топ_orig = pd.Series(рейтинг_orig).sort_values(ascending=False).head(5)
print("Неправильно (із посмертним показником 'Дата розтину'):")
print(топ_orig.round(3).to_string())

ознаки_clean = [c for c in df.select_dtypes('number').columns if c not in ['помер/жив', 'Дата розтину']]

рейтинг_clean = {}
for c in ознаки_clean:
    r = df[c].corr(ціль)
    if pd.notna(r):
        рейтинг_clean[c] = abs(r)

топ_clean = pd.Series(рейтинг_clean).sort_values(ascending=False).head(5)
print("\nПравильно (предиктори без витоку даних):")
print(топ_clean.round(3).to_string())
```

```
Помилка 2: Нестандартизовані категорії статі

Неправильно (4 статі через різний формат запису):
Кількість унікальних статей: 4
Стать
ж      56
ч      34
жін    19
чол    12

Правильно (після уніфікації синонімів):
Кількість унікальних статей: 2
Стать
ж    75
ч    46
------------------------------------------------------------
Помилка 5: Змішування відсотків та часток у SpO2

Неправильно (з урахуванням дробу 0.9 як мінімуму):
  середнє  : 82.05
  мінімум  : 0.9

Правильно (усі значення зведені до відсотків):
  середнє  : 82.79
  медіана  : 84.0
  мінімум  : 50.0
  максимум : 98.0
------------------------------------------------------------
Помилка 10: Витік даних через 'Дату розтину'

Неправильно (із посмертним показником 'Дата розтину'):
Дата розтину    1.000
Лім2            0.645
ІЛ6-2           0.616
Л2              0.480
Вік             0.449

Правильно (предиктори без витоку даних):
Лім2     0.645
ІЛ6-2    0.616
Л2       0.480
Вік      0.449
П/Я2     0.395
```

Етап 7. Висновки та індивідуальне питання

```
ВИСНОВКИ = [
    # три висновки, кожен — повне речення про ваші дані, а не загальна фраза
    '''У датасеті виявлено велику кількість пропущених та ненормалізованих даних (наприклад, показник КТ
    заповнений лише для 44 пацієнтів із 121, а стовпчик "Т вище 37,5" з кількістю днів містить змішані текстово-числові записи)''',
    ''''Очищення даних від витоку через посмертні показники виявило, що найсильнішими реальними предикторами
    летальності є рівень лімфоцитів (Лім2), інтерлейкін-6 (ІЛ6-2) та лейкоцитів (Л2)''',
    'Датасет має збалансований розподіл за результатами лікування: частка пацієнтів, які одужали, та летальних випадків становить по 50%'
]
assert len(ВИСНОВКИ) >= 3 and all(len(в) >= 60 for в in ВИСНОВКИ), \
    'Потрібні три змістовні висновки'
for i, в in enumerate(ВИСНОВКИ, 1):
    print(f'{i}. {в}')
```

```
1. У датасеті виявлено велику кількість пропущених та ненормалізованих даних (наприклад, показник КТ
    заповнений лише для 44 пацієнтів із 121, а стовпчик "Т вище 37,5" з кількістю днів містить змішані текстово-числові записи)
2. 'Очищення даних від витоку через посмертні показники виявило, що найсильнішими реальними предикторами
    летальності є рівень лімфоцитів (Лім2), інтерлейкін-6 (ІЛ6-2) та лейкоцитів (Л2)
3. Датасет має збалансований розподіл за результатами лікування: частка пацієнтів, які одужали, та летальних випадків становить по 50%
```

```
print('ВАШЕ ПИТАННЯ:'); print(В['питання']); print()
ВІДПОВІДЬ = '''У файлі ідентифікаторами є 3 стовпці: "номер і/х" (номер історії хвороби), "ПІП" та "Телефон".
Всі значення цих стовпців є унікальними та не мають статистичної цінності.
Автоматично виявити ідентифікатори без аналізу їхніх назв можна за такими критеріями:

1. Всі значення у стовпці є унікальними
2. Зазвичай текстовий тип даних (object/string) або цілі числа, для яких математичні обчислення не мають жодного сенсу
3. Стабільна довжина рядка або специфічні паттерни (для текстових ID), які фіксуються регулярними виразами
4. Послідовне зростання чисел з кроком 1 (для числових ID)
'''
assert len(ВІДПОВІДЬ.strip()) >= 200, 'Відповідь має бути розгорнутою (від 200 символів)'
print(ВІДПОВІДЬ)
```

```
ВАШЕ ПИТАННЯ:
Скільки стовпців файлу є ідентифікаторами? Як їх розпізнати автоматично, не дивлячись на назви?

У файлі ідентифікаторами є 3 стовпці: "номер і/х" (номер історії хвороби), "ПІП" та "Телефон".
Всі значення цих стовпців є унікальними та не мають статистичної цінності.
Автоматично виявити ідентифікатори без аналізу їхніх назв можна за такими критеріями:

1. Всі значення у стовпці є унікальними
2. Зазвичай текстовий тип даних (object/string) або цілі числа, для яких математичні обчислення не мають жодного сенсу
3. Стабільна довжина рядка або специфічні паттерни (для текстових ID), які фіксуються регулярними виразами
4. Послідовне зростання чисел з кроком 1 (для числових ID)
```

Етап 8. Декларація про використання інструментів ШІ

Користуватися мовними моделями дозволено. Це нормальна інженерна практика.

Обов'язковою є прозорість: ви вказуєте, де саме і як скористалися інструментом — так само, як у науковій статті вказують використане програмне забезпечення. Задекларована допомога порушенням не є.

Порушенням є інше: здати роботу, яку ви не можете пояснити. На захисті вас попросять показати конкретний рядок свого коду, пояснити, чому він саме такий, і внести в нього невелику зміну на місці. Для кожного етапу оберіть одне з формулювань:

- `'ні'` — інструментами ШІ не користувався
- `'синтаксис'` — питав про назву функції або синтаксис, код писав сам
- `'код, перевірено'` — код згенеровано, я його прочитав, перевірив і розумію
- `'текст, перероблено'` — згенеровано чернетку тексту, яку я переписав по суті

- `'текст, як є'` — згенерований текст залишено майже без змін

```
ДЕКЛАРАЦІЯ = {
    'етап 1 — паспорт змінних':        'ні',
    'етап 2 — допустимі статистики':   'код, перевірено',
    'етап 3 — безглузді числа':  'синтаксис', 'етап 4 —
    міра зв'язку':   'синтаксис',
    'етап 5 — підготовка до моделі':   'код, перевірено',
    'етап 6 — виправлення аналізу':    'текст, перероблено',
    'етап 7 — висновки й відповідь':   'текст, перероблено',
}

ЩО_САМЕ_Я_ПЕРЕВІРИВ = 'за допомогою ШІ було згенеровано код для обчислення д
ПІДТВЕРДЖУЮ = True     # я можу пояснити кожен рядок свого коду
                        # і внести в нього зміни на вимогу під час захисту
```

```
# --- ФІНАЛЬНА САМОПЕРЕВІРКА ---
ФОРМУЛЮВАННЯ = {'ні', 'синтаксис', 'код, перевірено', 'текст, перероблено',

перевірки = {
    'заповнено титульні поля':   bool(ПРІЗВИЩЕ_ІМЯ and ГРУПА and НОМЕР) 'етап
    1: паспорт із 8 стовпців': all(ПАСПОРТ[c][0] and ПАСПОРТ[c][1] fo 'етап
    3: три безглузді числа':     len(БЕЗГЛУЗДІ) >= 3,
   'етап 4: міру обрано й пояснено': bool(ОБРАНА_МІРА and len(ЧОМУ_САМЕ_ВОН
     'етап 5: підготовку описано': all(len(ПІДГОТОВКА[c].strip()) >= 15 f
    'етап 6: знайдено 10 помилок':    len(ВИПРАВЛЕННЯ) == 10
    'етап 6: знайдено 10 помилок':    len(ВИПРАВЛЕННЯ) == 10,
    'етап 7: три висновки':           len(ВИСНОВКИ) >= 3,
    'етап 7: відповідь на питання':   len(ВІДПОВІДЬ.strip()) >= 200,
     'декларацію заповнено': all(v in ФОРМУЛЮВАННЯ for v in ДЕКЛАРА 'опис
      перевірки ≥ 120 символів': len(ЩО_САМЕ_Я_ПЕРЕВІРИВ.strip()) >= 12
    'підтвердження авторства':        ПІДТВЕРДЖУЮ is True,
}

print('ЧЕК-ЛИСТ ГОТОВНОСТІ')
print('=' * 52) for назва, ок in
перевірки.items():
    print(('  ГОТОВО     ' if ок else '  НЕ ГОТОВО ') + назва)
print('=' * 52)

assert all(перевірки.values()), 'Робота не готова до здачі — див. чек-лист в
print() print(f'Робота варіанта {В["варіант"]} готова до захисту.')
print(f'{ПРІЗВИЩЕ_ІМЯ}, {ГРУПА}')
```

```
ЧЕК-ЛИСТ ГОТОВНОСТІ
====================================================
  ГОТОВО     заповнено титульні поля
  ГОТОВО     етап 1: паспорт із 8 стовпців
  ГОТОВО     етап 3: три безглузді числа
```

```
  ГОТОВО     етап 4: міру обрано й пояснено
  ГОТОВО     етап 5: підготовку описано
  ГОТОВО     етап 6: знайдено 10 помилок
  ГОТОВО     етап 7: три висновки
  ГОТОВО     етап 7: відповідь на питання
  ГОТОВО     декларацію заповнено
  ГОТОВО     опис перевірки ≥ 120 символів
  ГОТОВО     підтвердження авторства
==================================================

Робота варіанта 16 готова до захисту.
Потапова Світлана, ШІ-31
```

Перед здачею

Виконайте **Kernel → Restart & Run All**. Ноутбук має пройти згори донизу без жодної помилки — це перше, що перевіряється на захисті.